

2026 《人工智能导论》大作业

任务名称： 可解释的谣言检测

完成组号： _____

小组人员： 吴俊逸、李陆宸、安燕杰

完成时间： _____

1. 任务目标

本项目构建可解释谣言检测模型。输入一条推文，输出二分类标签：0 为非谣言，1 为谣言；同时生成文字说明判断依据。目标是在合理运行时间内提高 `val.csv` 准确率，并保证结果可复现、解释可读。

2. 具体内容

(1) 实施方案

系统采用“监督分类器 + 大模型解释/复核”的两阶段方案。第一阶段用 RoBERTa-Large 微调并承担主要分类；第二阶段调用上海交大 OpenAI 兼容 API 生成依据。为避免大模型不稳定覆盖监督模型，只在 RoBERTa 低置信时使用 deepseek-reasoner 复核。

文本预处理包括：URL→[URL]，用户→[USER]，话题→[HASHTAG] 话题词。训练使用 cosine schedule、warmup、label smoothing、gradient clipping 和 early stopping。最佳监督 checkpoint 为 roberta-large，seed=42，lr=1e-5，epoch=6。

(2) 核心代码分析

核心模块在 `src/rumor_detection/`。RumourDetector 负责加载 tokenizer 和 RoBERTa：`classify()` 清洗文本后计算 logits，返回最大概率类别；`explain()` 将原文和标签组成提示词，调用交大 API 生成依据；`detect()` 返回 `{"label": ..., "explanation": ...}`。


`llm_client.py` 统一管理 API，默认 `base_url` 为 `https://models.sjtu.edu.cn/api/v1`，密钥从 `.env` 或 `SJTU_API_KEY` 读取。训练脚本在 `scripts/training/`，评估脚本在 `scripts/evaluation/`。

(3) 检测结果分析


401 条验证集上，监督模型准确率为 **90.02%**；只复核 4 条低置信样本后，hybrid 准确率为 **90.27%**。

Validation Result Summary

Accuracy



Hybrid Confusion Matrix



LLM reviewed 4 uncertain samples; corrected

方法	Accuracy	混淆矩阵 [[TN, FP], [FN, TP]]
RoBERTa-Large	90.02%	[[203, 23], [17, 158]]
RoBERTa-Large + 低置信 LLM 复核	90.27%	[[204, 22], [17, 158]]

最终 hybrid 指标：

类别	Precision	Recall	F1
非谣言(0)	0.92	0.90	0.91
谣言(1)	0.88	0.90	0.89

LLM 复核修正 1 个 false positive，未引入新错误；但扩大复核范围会造成错误覆盖。因此 RoBERTa 应作为主分类器，LLM 更适合解释和少量困难样本复核。

(4) 判断依据分析

解释阶段要求大模型围绕信息来源、表述客观性、情绪化词汇、事实可验证性等维度生成依据。对含有“BREAKING”、身份指认、未经证实细节的推文，解释会指出其事实断言具体但来源不足；对官方更新、个人评论或无明确事实断言的文本，则倾向说明其不构成谣言。这样输出不仅有标签，也能展示可理解的判断线索。

3. 工作总结

(1) 收获、心得

小规模文本分类中，预训练模型微调仍然有效；TF-IDF baseline 适合快速建立参照，但 RoBERTa-Large 明显提升上限。大模型适合解释和辅助复核，但不宜替代稳定的监督分类器。

(2) 遇到问题及解决思路

早期尝试 DeBERTa 时 tokenizer 依赖复杂，改用 RoBERTa。API 密钥不能硬编码，改为 `.env` 和环境变量读取。当前环境读取 fast tokenizer 报错，推理和评估改为 `use_fast=False`，继续使用同一套 `vocab.json` 与 `merges.txt`，不改变模型权重。LLM 大范围复核会降低准确率，因此限制在最低置信样本上。

4. 课程建议

建议增加一次从数据清洗、训练、评估到报告生成的完整示例；同时提供提交检查清单，帮助同学组织性能、可解释性和工程复现内容。